

# Lista de Exercícios 2 de Análise Numérica

Prof.: Fabrício Murai

Informações importantes:

- Data de entrega: até 23:59 do dia 05/04/2018.
- Questões podem ser discutidas entre até três alunos. Nomes dos colegas precisam ser listados. Contudo, a escrita das soluções e submissão deve ser feita individualmente.
- Submissão deve ser feita em formato PDF através do Moodle, mesmo que tenham sido resolvidas a mão e escaneadas.
- Todas as soluções devem ser justificadas.
- Se puder, peço por favor que marque o tempo gasto para resolver a lista, para que o tamanho da lista de exercícios seja ajustado em semestres futuros.

1. Considere o sistema linear  $Ax = b$ , onde a matriz  $A = \begin{bmatrix} 9 & 18 \\ 18 & 52 \end{bmatrix}$  é simétrica e definida positiva.

(a) Sendo  $b = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$ , encontre a solução usando a Decomposição de Cholesky.

(b) Sendo  $b = \begin{bmatrix} 6 \\ 8 \end{bmatrix}$ , encontre a solução usando a Decomposição de Cholesky.

2. Refinamento de solução baseado na matriz  $A$  anterior.

(a) Para  $b = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$ , calcule o erro residual ( $r = b - Ax$ ) da solução aproximada dada por  $x^{(0)} = \begin{bmatrix} 0,5 \\ -0,1 \end{bmatrix}$ .

(b) Use  $r$  para executar um refinamento da solução  $x^{(0)}$ .

3. Assinale **V** para verdadeiro ou **F** para falso e **justifique**:

( ) A decomposição de Cholesky pode ser aplicada a qualquer matriz  $A^T A$  tal que as entradas de  $A$  são números reais.

( ) A fatoração LU de uma matriz quadrada  $A$  de posto  $n$  pode resultar em uma matriz  $U$  com linhas nulas.

( ) A fatoração LU é aproximadamente duas vezes mais demorada que a fatoração Cholesky, mas ambas requerem o mesmo espaço em memória.

4. Dada a matriz  $A = \begin{bmatrix} 3 & 0 & 2 \\ 9 & 1 & 7 \\ 1 & 0 & 1 \end{bmatrix}$  e sua inversa  $A^{-1} = \begin{bmatrix} 1 & 0 & -2 \\ -2 & 1 & -3 \\ -1 & 0 & 3 \end{bmatrix}$ , calcule o número de condicionamento segundos as normas:

(a) Norma-1. É bem condicionado?

(b) Norma-infinito. É bem condicionado?

(c) Considere um erro na medição do vetor  $b = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$ , resultando no vetor  $b' = \begin{bmatrix} 1,1 \\ 1,9 \\ 3,0 \end{bmatrix}$ . Usando o número de condição calculado a partir da norma-infinito, determine o limite superior do erro da aproximação encontrada ao se resolver  $Ax = b'$ .

5. Assinale **V** para verdadeiro ou **F** para falso e **justifique**:

- ( ) Toda matriz  $A \in \mathbb{R}^{m \times n}$  possui um SVD.
- ( ) Na decomposição SVD  $A = U\Sigma V^\top$ , as colunas de  $U$  são ortogonais às linhas de  $V$ .
- ( ) Se  $A$  é singular, pelo menos um dos autovalores de  $A$  é nulo.

6. Seja  $C = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \\ -1 & 1 \end{bmatrix}$ .

(a) Mostre que

$$U = \begin{bmatrix} -0.632 & 0.000 \\ 0.316 & -0.707 \\ -0.316 & -0.707 \\ 0.632 & 0.000 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 2.236 & 0.000 \\ 0.000 & 1.000 \end{bmatrix} \quad V^\top = \begin{bmatrix} -0.707 & 0.707 \\ -0.707 & -0.707 \end{bmatrix}$$

é o SVD de  $C$ . Você pode usar:

- i. a decomposição espectral de  $C^\top C = V\Lambda V^\top$  e encontrar  $U$  usando a relação  $Cv_i = \sigma_i u_i \Rightarrow u_i = \frac{Cv_i}{\sigma_i}$  ou
  - ii. o fato de que o SVD é único quando todos os valores singulares de uma matriz são não-degenerados (não aparecem com multiplicidade maior que 1) e não-zero.
- (b) Suponha que a matriz  $C$  denota a opinião de quatro usuários sobre dois sites na Internet (-1: negativa, 0: neutra, 1: positiva). Vamos identificar os pares de usuários mais semelhantes. Uma forma de medir a semelhança entre dois usuários representados pelos vetores  $u$  e  $v$  é calcular o cosseno do ângulo  $\theta$  formado entre eles:

$$\cos(\theta) = \frac{u \cdot v}{\|u\|\|v\|}.$$

Identifique para cada vetor, o outro vetor com que ele mais se assemelha. Refaça as contas utilizando a matriz  $U$ . O que você observou?

- (c) Suponha que queremos adicionar informação sobre um novo usuário que tem opinião positiva sobre os dois sites  $w = (1, 1)$  à matriz  $U$ , sem recalculá-lo o SVD. Como seria a representação deste usuário?

7. Seja  $A$  uma matriz  $m \times n$ . O SVD reduzido de  $A$  retorna  $U_{m \times k} \Sigma_{k \times k} V_{k \times n}^\top$ . Já o SVD truncado de posto  $r < \min(m, n)$  retorna apenas as  $r$  primeiras colunas de  $U$ , os  $r$  maiores valores singulares de  $\Sigma$  e as  $r$  primeiras linhas de  $V^\top$ .

Uma propriedade importante do SVD truncado é que ele retorna a melhor aproximação  $A_r$  para uma matriz  $A$  dentre todas as matrizes de posto  $r$ , onde a qualidade da aproximação é medida por  $\|A - A_r\|_F$ , onde  $\|B\|_F = \sqrt{\sum_i \sum_j B_{i,j}^2}$  é a norma de Frobenius.

Nesta questão, vamos ver como a qualidade da aproximação aumenta com  $r$ . Primeiramente, vamos gerar uma matriz aleatória  $A_{10 \times 8}$ . Em seguida, vamos encontrar a decomposição SVD reduzida. Depois disso, vamos variar o número  $r$  de valores singulares considerados para encontrar aproximações  $A_r$  para, finalmente, calcular  $\|A - A_r\|_F$ . Você pode criar uma tabela com os erros ou um gráfico, se preferir.

```

import numpy as np
m = 10; n = 8

A = ??? # criar uma matriz aleatoria 10 x 8
U, Sigma, Vt = np.linalg.svd(A)

erro = np.zeros(n)
A_r = np.zeros((m,n))
for r in range(min(m,n)):
    # calcular a aproximacao A_r de posto r para A
    A_r += np.outer(??? * Sigma[r], ???)
    erro[r] = np.linalg.norm(???)

print(erro)

```

8. Dada a decomposição espectral de  $A = \begin{pmatrix} 5 & 2 \\ 2 & 5 \end{pmatrix}$  em  $A = Q\Lambda Q^\top$ , onde  $Q = \begin{pmatrix} 0.707 & -0.707 \\ 0.707 & 0.707 \end{pmatrix}$  e  $\Lambda = \begin{pmatrix} 7 & 0 \\ 0 & 3 \end{pmatrix}$ , calcule:

- (a) a inversa da matriz  $A$ , e
- (b) a potência  $A^{50}$ .
- (c) o produto  $A^{50}w$ , por uma sequência de vetores aleatórios  $w_1, \dots, w_{10}$  e normalize o resultado para obter um vetor unitário. Qual a relação entre o resultado obtido e os autovetores de  $A$ ?